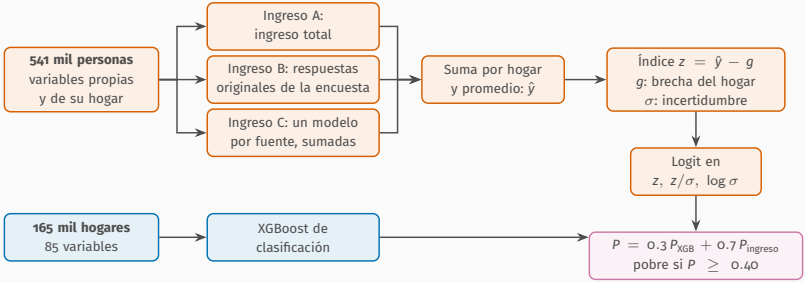
Predecir la pobreza en Colombia

Best Model Deep Dive

Equipo 1: Jonathan Cadena, Mauricio Aragón y Esteban Flórez

Problem Set 2 • Octubre de 2026

Nuestro mejor modelo



Especificación (boosting): $P = 0.3\,P_{\text{XGBoost}} + 0.7\,P_{\text{ingreso}}$. El XGBoost clasifica con 85 variables del hogar. P_{ingreso}: tres LightGBM predicen el ingreso de cada persona; se suma por hogar, se promedian y se compara con la brecha del hogar; un logit lo convierte en probabilidad según qué tan incierta es la predicción (σ). Pobre si $P \geq 0.40$.

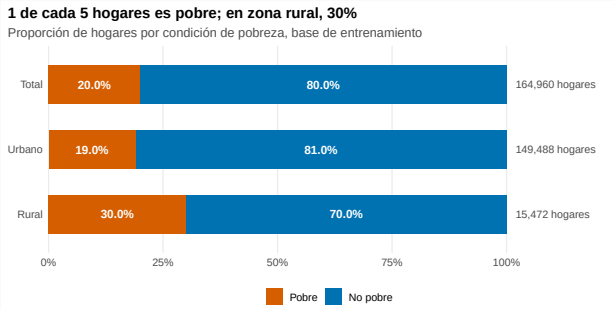
0.77 Kaggle público

0.77 Kaggle privado

0.776 F1 validación cruzada

1. Predecir el ingreso de cada persona vale más que cambiar de algoritmo.
2. El desbalance se maneja con el umbral, no rebalanceando.
3. Sin el módulo de ingresos, una encuesta corta cae a F1 0.69.

La pobreza es una regla sobre el ingreso, y 1 de cada 5 hogares es pobre



Predecir que ningún hogar es pobre acierta en el 80% de los casos (accuracy), pero no identifica a ningún hogar pobre (F1 = 0). Por eso los modelos se evalúan con F1 y se ajusta el umbral de clasificación.

Regla oficial del DANE, reescrita

$$\text{Pobre} = 1 \iff S < G$$

$S = \sum_{j \in UG} \text{Ingtot}_j$: ingreso de las personas
$G = L_p \times N_{ug} - R$: brecha ($R$: arriendo imputado)

Reproduce el 99.99 % de la pobreza de train.

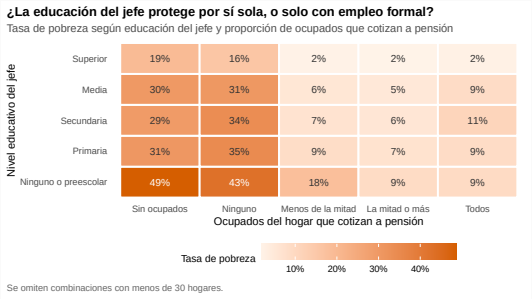
G **se conoce en test** (línea, personas y arriendo): solo hay que predecir *S*.

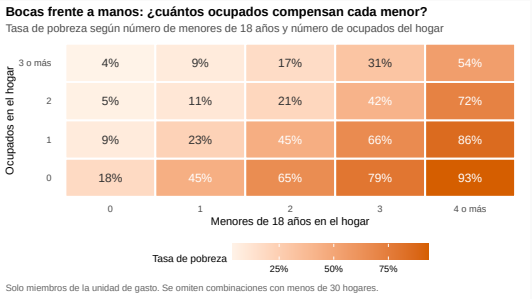
S **vive en las personas**: el ingreso es la suma de lo que gana cada miembro.

Desbalance: 20 % pobres. Con F1, predecir "nadie es pobre" da 0.

Lo que predice la pobreza: trabajo formal, dependencia y vivienda

Con empleo formal la pobreza baja a 2–11 %; con muchos menores y pocos ocupados llega al 93 %





Razonamiento económico: el ingreso del hogar ≈ ocupados × calidad del empleo, repartido entre sus miembros. La vivienda (arriendo por persona) resume el ingreso permanente.

El ingreso tiene cinco fuentes con procesos muy distintos

Componente	% del ingreso	% que lo recibe
Trabajo	78	43.7
Pensiones	12	4.8
Ayudas (hogares, instituciones)	5	13.0
Arriendos e intereses	4	3.3
Desocupados	1	1.2

Los componentes suman exactamente `Ingtot` en el 100 % de las personas de train.

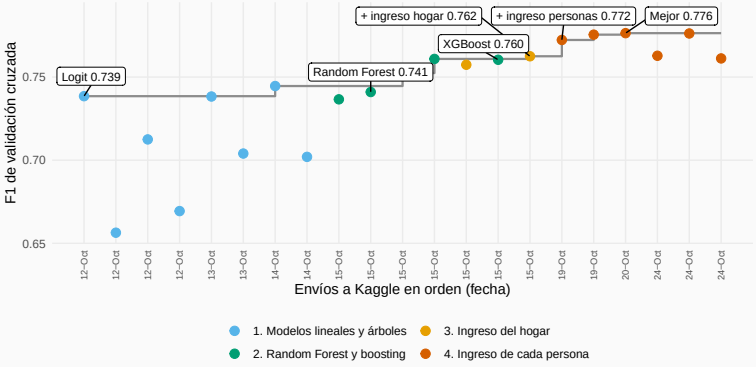
Por qué modelar a las personas

- El salario depende de la posición ocupacional, la cotización y el oficio de cada miembro.
- Las pensiones son el 12 % del ingreso pero las recibe el 5 % de las personas: un monto grande y casi fijo.
- Un modelo a nivel hogar solo ve promedios; uno por persona ve quién genera el ingreso.

Cómo llegamos aquí: 21 envíos, cuatro etapas

21 envíos en dos semanas: cada etapa respondió a lo que aprendimos en la anterior

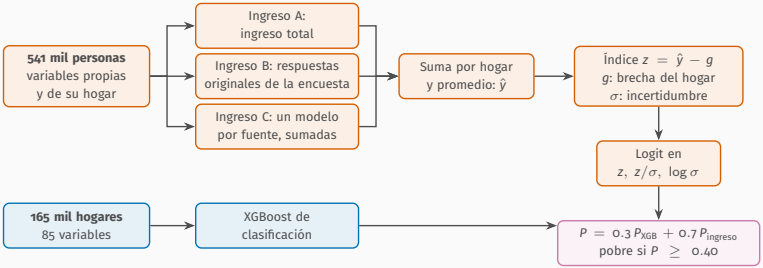
Puntos: F1 de validación cruzada de cada envío. Línea: mejor F1 alcanzado hasta ese envío



Reglas que mantuvimos en todo el proceso

- Los mismos 5 grupos de validación para todos los modelos.
- Hiperparámetros por búsqueda en grilla con validación cruzada.
- Umbral: el que maximiza el F1 fuera de muestra.
- Decidimos con la validación cruzada, no con el puntaje público.

Arquitectura y entrenamiento: del ingreso de cada persona a una probabilidad



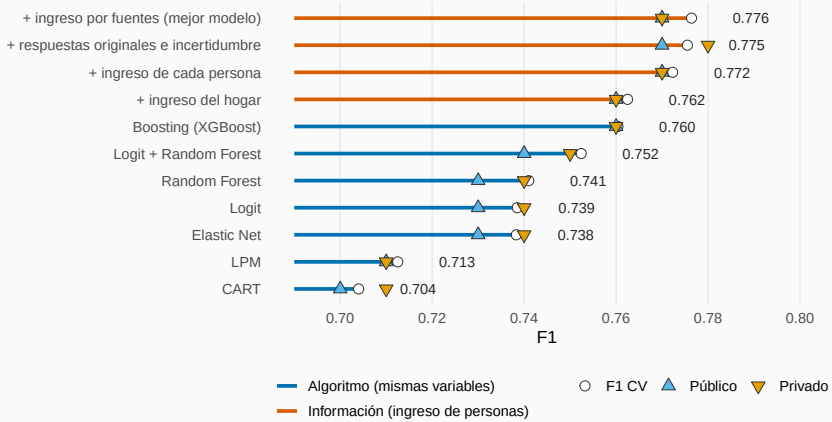
Pieza	Unidad	Algoritmo	Hiperparámetros	F1
Clasificador (peso 0.3)	Hogar	XGBoost	800 árboles de profundidad 6	0.760
Ingreso A: total	Persona	LightGBM Tweedie	2200 árboles de 63 hojas	0.766
Ingreso B: respuestas originales	Persona	LightGBM Tweedie	1000 árboles; más peso cerca de la línea	0.768
Ingreso C: por fuentes	Persona	5 LightGBM Tweedie	5 modelos de 800 árboles	0.767
Índice de ingreso (peso 0.7)	Hogar	Promedio + logit	z, z/σ, $\log\sigma$	0.775
Mejor modelo	**Hogar**	**Ensamble**	**pesos 0.3 / 0.7, umbral 0.40**	**0.776**

F1 de validación cruzada con 5 grupos de hogares (cada persona queda en el grupo de su hogar). Pérdida Tweedie: apta para ingresos con muchos ceros y una cola larga.

Cada pieza suma: el algoritmo llega a 0.76, la información a 0.78

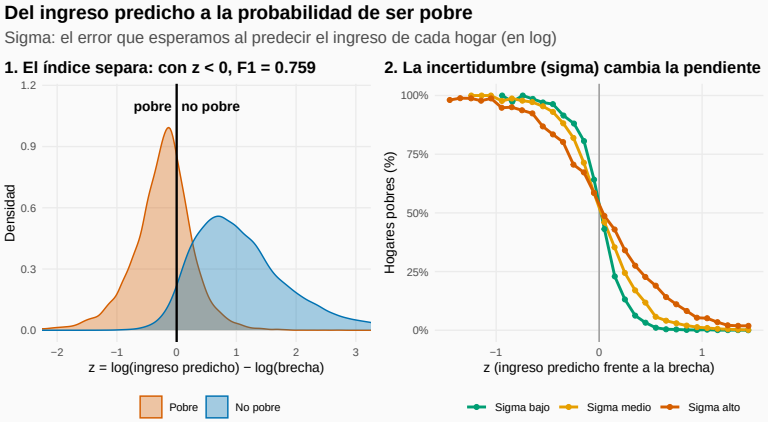
El algoritmo lleva el F1 a 0.76; la información de las personas, a 0.78

F1 de validación cruzada (5 folds) y puntajes de Kaggle (redondeados a 2 decimales)



Público: 20 % de test (unos 13 mil hogares). Privado: 80 % restante.

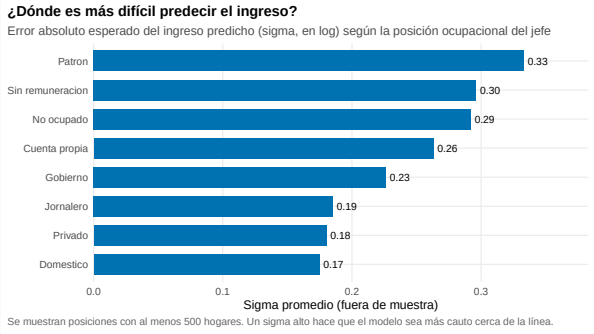
Del ingreso predicho a la probabilidad de ser pobre



z: distancia entre el ingreso predicho y la brecha. σ: error esperado al predecir el ingreso del hogar.

$$\text{logit}\, P(\text{Pobre}) = b_0 + b_1 z + b_2 \frac{z}{\sigma} + b_3 \log \sigma$$

Incertidumbre σ: la misma distancia a la línea no pesa igual en todos los hogares



Ejemplo: dos hogares con $z = -0.3$

Ingreso predicho 26 % por debajo de la brecha. Si el error fuera normal, $P(\text{Pobre}) \approx \Phi(-z/\sigma)$:

- Jefe asalariado privado, $\sigma = 0.18$: 0.95
- Jefe patrón, $\sigma = 0.33$: 0.82

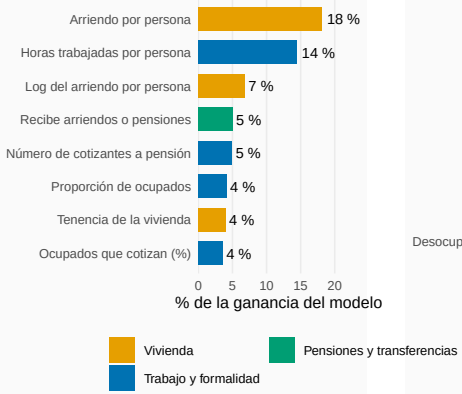
- Cuenta propia y no ocupados: 64 % de los hogares y el 83 % de los pobres, con σ alto.
- σ sube el F1 del ingreso solo de 0.766 a 0.770.
- Política: verificar en campo los hogares con σ alto.

Importancia: vivienda y trabajo formal en el hogar; posición ocupacional en las personas

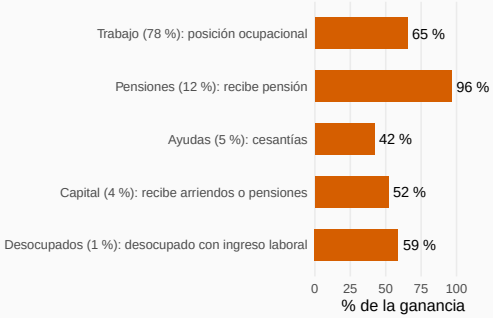
Qué variables usa el mejor modelo

Entre paréntesis, el peso de cada fuente en el ingreso total de las personas

Clasificador del hogar



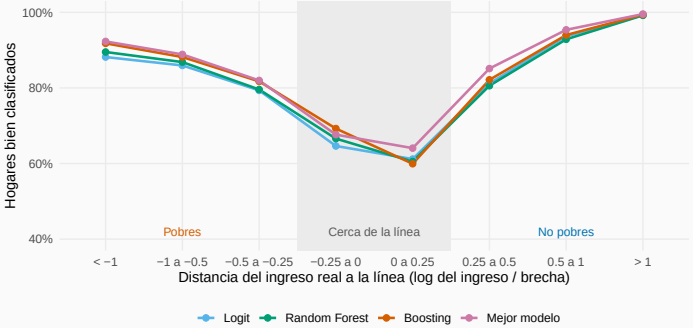
Ingreso por fuentes: variable principal



Diagnóstico: los errores están cerca de la línea

Todos fallan cerca de la línea: ahí está más de la mitad de los errores

Fuera de muestra. En la franja gris está el 56 % de los errores del mejor modelo

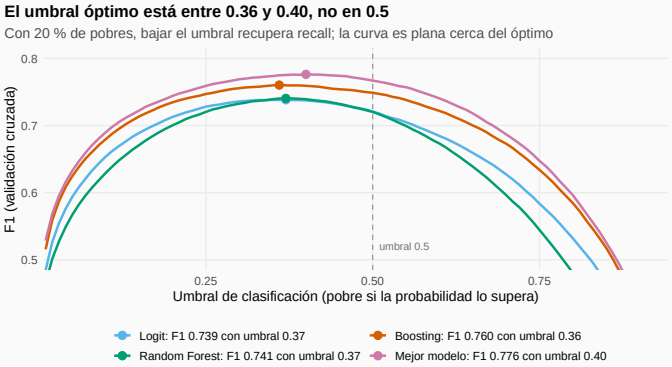


- El 56 % de los errores son hogares a menos de ± 0.25 log de su brecha: ruido casi irreducible.
- Lejos de la línea acierta más del 90 %.

F1 por grupo (mejor modelo)

Grupo	F1	Pobreza
Urbano	0.779	19 %
Rural	0.759	30 %
Hogar de 1 persona	0.654	9 %
Hogar de 6 o más	0.859	41 %

El desbalance se maneja con el umbral, no rebalanceando



- Con umbral 0.5 el mejor modelo pierde 0.01 de F1; el logit, 0.02.
- **Rebalancear** (duplicar pobres hasta 50/50) en el árbol: F1 0.702 frente a 0.704. Infla todas las probabilidades, pero el orden de los hogares no cambia: el umbral óptimo solo pasó de 0.30 a 0.74.
- Elegir el umbral por F1 ya corrige el desbalance.

Matriz de confusión: 1 de cada 5 pobres queda por fuera

Real	Predicho pobre	Predicho no pobre	Total
Pobre	26,632 (80.6 %)	6,392 (19.4 %)	33,024
No pobre	8,952 (6.8 %)	122,984 (93.2 %)	131,936

Predicciones fuera de muestra de los 164,960 hogares de train, umbral 0.40. % por fila.

161
pobres cubiertos

39
pobres excluidos

54
no pobres incluidos

Por cada 1,000 hogares, con umbral 0.40 (predicciones fuera de muestra).

Dos errores con costos distintos

- **Exclusión** (falso negativo): un pobre queda por fuera; 19.4 % de los pobres.
- **Inclusión** (falso positivo): un no pobre recibe el beneficio; 25.2 % de los beneficiarios.

¿Cuánto cuesta cada error?

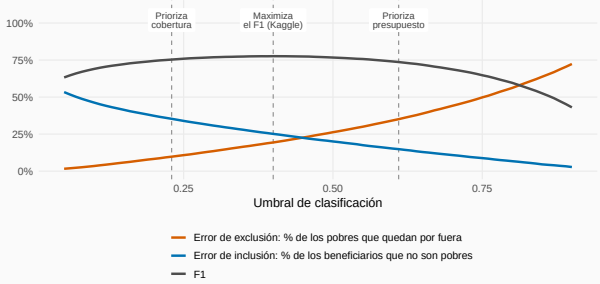
Si excluir a un pobre cuesta c veces más que incluir a un no pobre, se marca pobre si $P \geq 1/(1+c)$: con $c = 2$, umbral 0.33.

Bajar de 0.40 a 0.30 cuesta solo 0.007 de F1 y sube el recall a 86.5 %.

El umbral decide entre errores de exclusión e inclusión

Menos exclusión de pobres implica más inclusión de no pobres

Mejor modelo, predicciones fuera de muestra: tres umbrales para tres objetivos de política



Escenario	Umbral	Hogares marcados	Error de exclusión	Error de inclusión	F1
Prioriza cobertura	0.23	28 %	10 %	35 %	0.753
Maximiza el F1 (Kaggle)	**0.40**	**22 %**	**19 %**	**25 %**	**0.776**
Prioriza presupuesto	0.61	15 %	35 %	15 %	0.737

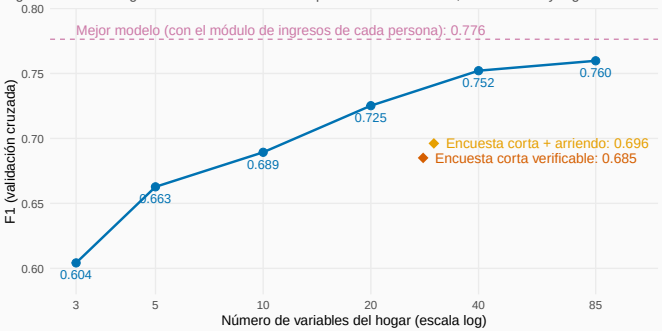
Exclusión: % de los hogares pobres que el modelo deja por fuera. Inclusión: % de los hogares marcados como pobres que no lo son.

- El F1 pesa igual los dos errores y escoge 0.40.
- **Cobertura** (umbral 0.23): exclusión de 10 %, inclusión de 35 %.
- **Presupuesto fijo** (0.61): inclusión de 15 %, exclusión de 35 %.
- El umbral se fija según el costo social de cada error.

¿Se puede usar con una encuesta corta?

Recortar la encuesta cuesta F1: con 10 variables cae de 0.76 a 0.69

LightGBM a nivel hogar con las k variables más importantes del XGBoost; mismos folds y regla de umbral



Recomendación

1. Recortar cuesta: 10 variables dan 0.69; una encuesta corta verificable (vivienda, demografía, ocupados, cotizantes en PILA), 0.685.
2. El módulo de ingresos suma 0.09, pero es caro, y el arriendo autorreportado es manipulable con un subsidio en juego.
3. **Dos etapas:** encuesta corta para todos; módulo completo o visita solo cerca del umbral o con σ alto.

Conclusiones

1. Información

Entender la regla del DANE y modelar el ingreso de cada persona sube el F1 de 0.760 a 0.776. Es la mayor ganancia después de pasar a boosting.

2. Algoritmo y umbral

Con las mismas variables, el boosting le gana 0.02 al logit y al RF. El umbral (0.40) resuelve el desbalance mejor que rebalancear.

3. Política

El F1 pesa igual los errores de exclusión e inclusión: un programa debe elegir su umbral. Una encuesta corta verificable cuesta 0.09 de F1: usarla en dos etapas.

0.776	0.77	0.77
F1 validación cruzada	Kaggle público	Kaggle privado