Predecir la pobreza en Colombia

Best Model Deep Dive: un clasificador con un índice de ingreso

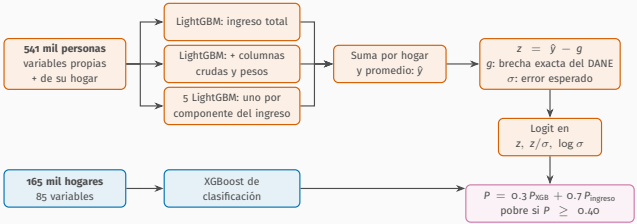
Equipo 1: Aragón, Cadena y Flórez

Problem Set 2 • Octubre de 2026

MECA 4107 Big Data y Machine Learning para Economía Aplicada — Universidad de los Andes

El mejor modelo en una diapositiva

Clasificamos con un índice de ingreso construido desde las personas



Especificación (boosting): $P = 0.3\,P_{\text{XGBoost}} + 0.7\,P_{\text{ingreso}}$. P_{ingreso}: promedio de tres LightGBM Tweedie del ingreso de cada persona, sumado por hogar, comparado con la brecha exacta del DANE y calibrado con la incertidumbre σ del hogar. Umbral 0.40, elegido por F1 fuera de muestra.

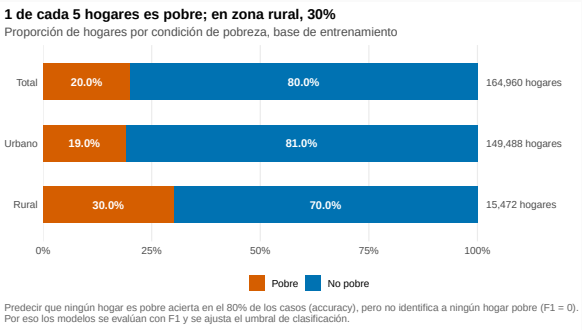
0.77 Kaggle público

0.77 Kaggle privado

0.776 F1 CV

1. Predecir el ingreso de cada persona vale más que cambiar de algoritmo.
2. El desbalance se maneja con el umbral, no rebalanceando.
3. Sin el módulo de ingresos, una encuesta corta cae a F1 0.69.

La pobreza es una regla sobre el ingreso, y 1 de cada 5 hogares es pobre



La regla del DANE, reconstruida en train

$$\text{Pobre} = 1 \iff S < G$$

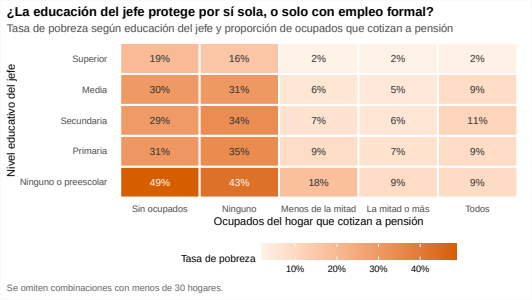
$S = \sum_{j \in UG} \text{Ingtot}_j$: ingreso de las personas
$G = L_p \times N_{ug} - R$: brecha ($R$: arriendo imputado)

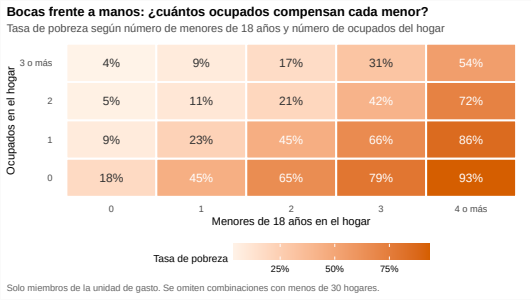
Reproduce el 99.99 % de la pobreza de train.

- G **se conoce en test** (línea, personas y arriendo): solo hay que predecir S.
- S **vive en las personas**: el ingreso es la suma de lo que gana cada miembro.
- **Desbalance:** 20 % pobres. Con F1, predecir "nadie es pobre" da 0.

Lo que predice la pobreza: trabajo formal, dependencia y vivienda

Con empleo formal la pobreza baja a 2–11 %; con muchos menores y pocos ocupados llega al 93 %





Razonamiento económico: el ingreso del hogar ≈ ocupados × calidad del empleo, repartido entre sus miembros. La vivienda (arriendo por persona) resume el ingreso permanente.

El ingreso tiene cinco fuentes con procesos muy distintos

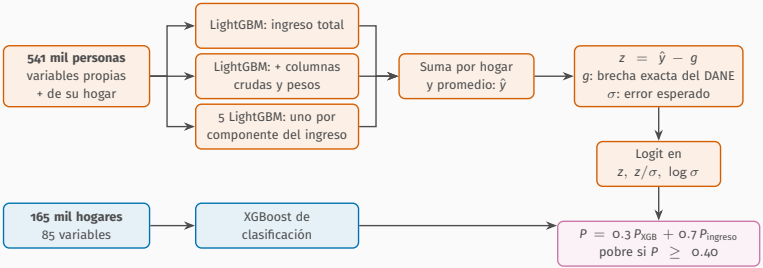
Componente	% del ingreso	% que lo recibe
Trabajo	78	43.7
Pensiones	12	4.8
Ayudas (hogares, instituciones)	5	13.0
Arriendos e intereses	4	3.3
Desocupados	1	1.2

Los componentes suman exactamente `Ingtot` en el 100 % de las personas de train.

Por qué modelar a las personas

- El salario depende de la posición ocupacional, la cotización y el oficio de cada miembro.
- Las pensiones son el 12 % del ingreso pero las recibe el 5 % de las personas: un monto grande y casi fijo.
- Un modelo a nivel hogar solo ve promedios; uno por persona ve quién genera el ingreso.

Arquitectura y entrenamiento: siete modelos, una probabilidad



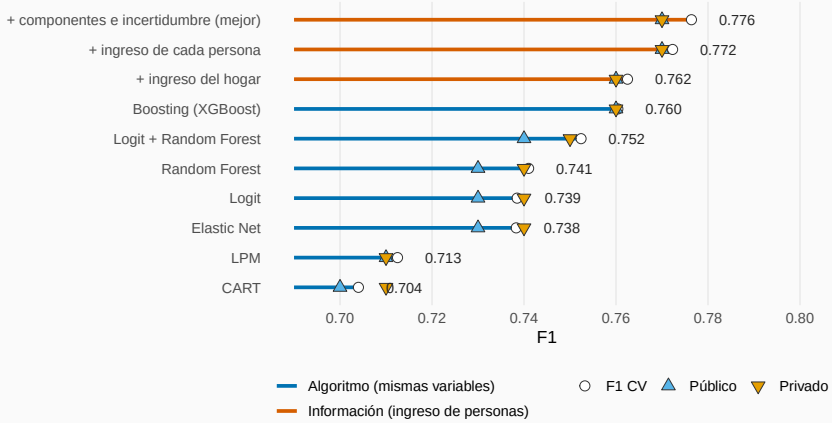
Pieza	Unidad	Algoritmo	Hiperparámetros	F1
Clasificador (peso 0.3)	Hogar	XGBoost	prof. 6, hoja mín. 20, η 0.05, 800 árboles	0.760
Ingreso total (17)	Persona	LightGBM Tweedie	63 hojas, η 0.05, 2200 árboles	0.766
Ingreso + crudas + pesos (20)	Persona	LightGBM Tweedie	63 hojas, η 0.1, 1000 árboles	0.768
Ingreso por componente (22)	Persona	5 LightGBM Tweedie	63 hojas, η 0.1, 800 árboles c/u	0.767
Ingreso promedio + σ (peso 0.7)	Hogar	LightGBM L1 + logit	σ: 31 hojas, 400 árboles	0.775
Mejor modelo	**Hogar**	**Ensamble**	**0.3 / 0.7, umbral 0.40**	**0.776**

F1 de validación cruzada (5 folds por hogar; las personas heredan el fold de su hogar). Tweedie 1.5 sobre el ingreso en millones; el ingreso de cada persona se suma por hogar.

Cada pieza suma: el algoritmo llega a 0.76, la información a 0.78

El algoritmo lleva el F1 a 0.76; la información de las personas, a 0.78

F1 de validación cruzada (5 folds) y puntajes de Kaggle (redondeados a 2 decimales)



Público: 20 % de test (unos 13 mil hogares). Privado: 80 % restante.

El índice de ingreso ya separa a pobres y no pobres



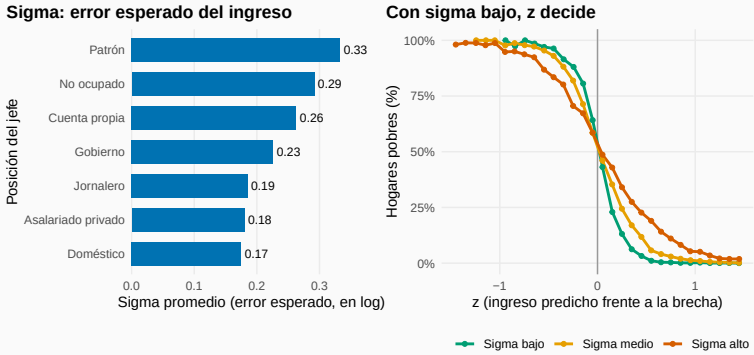
$$z = \log \hat{S} - \log G$$

- Sin umbral ni calibración, la regla $z < 0$ ya da F1 de 0.76.
- **Tweedie (1.5):** muchos ceros (niños, inactivos) y una cola larga; predice la media, así que la suma por hogar no se sesga.
- El error se concentra cerca de $z = 0$: ahí decide la calibración.

La incertidumbre por hogar: la misma z no significa lo mismo

La misma z no significa lo mismo para todos los hogares

Por eso la probabilidad se calibra con z, z/sigma y log(sigma)



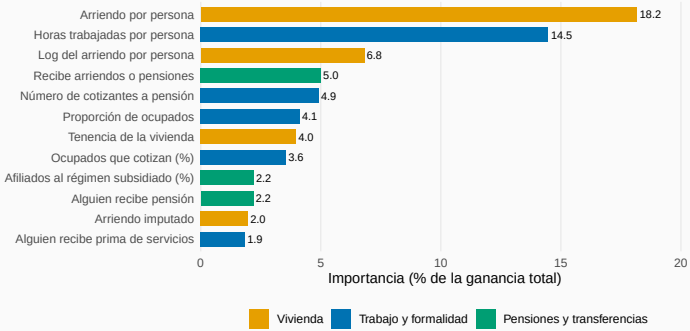
El ingreso de un asalariado privado se predice con un error de 0.18 (en log); el de un patrón, con 0.33.

$$\text{logit}\, P(\text{Pobre}) = b_0 + b_1 z + b_2 \frac{z}{\sigma} + b_3 \log \sigma$$

Importancia (I): el clasificador mira vivienda y trabajo formal

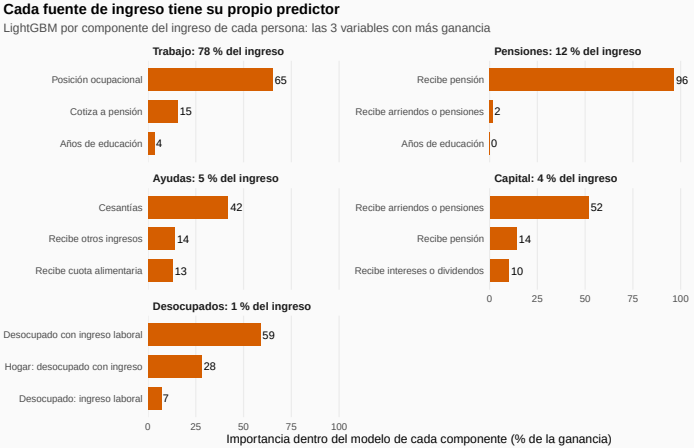
Vivienda y trabajo formal concentran más de la mitad de la ganancia

XGBoost de clasificación: las 12 variables con más ganancia (de 85)



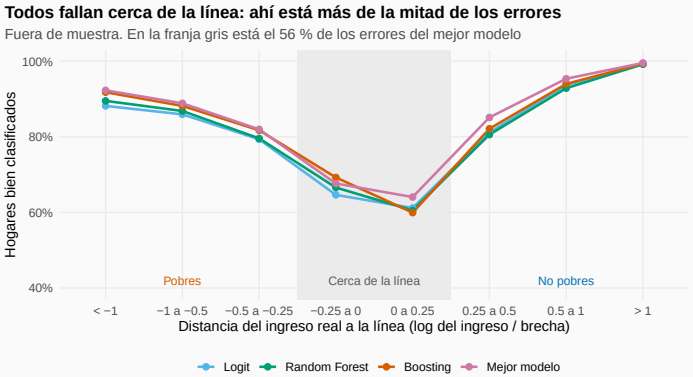
- **Arriendo por persona**: aproxima el ingreso permanente y el estrato.
- **Horas por persona** y **cotizantes**: cuánto trabajo hay y qué tan formal es.
- **Arriendos o pensiones**: ingresos que no dependen del empleo.

Importancia (II): cada fuente de ingreso tiene su predictor



- **Trabajo:** la posición ocupacional (asalariado, cuenta propia, patrón) y la cotización a pensión.
- **Pensiones:** una sola pregunta (“¿recibe pensión?”) explica el 96 %.
- Separar las fuentes evita que el modelo de trabajo “promedie” a los pensionados.

Diagnóstico: los errores están cerca de la línea

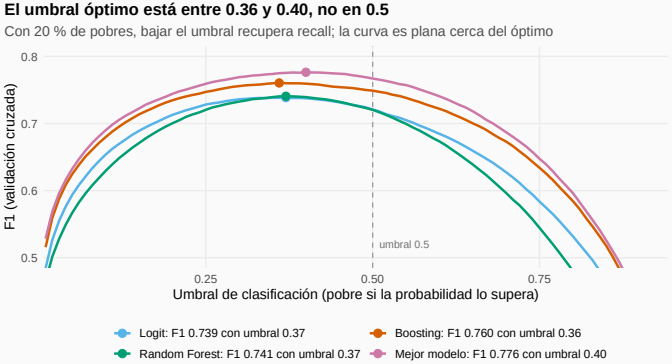


- El 56 % de los errores son hogares a menos de ± 0.25 log de su brecha: ruido casi irreducible.
- Lejos de la línea acierta más del 90 %.

F1 por grupo (mejor modelo)

Grupo	F1	Pobreza
Urbano	0.779	19 %
Rural	0.759	30 %
Hogar de 1 persona	0.654	9 %
Hogar de 6 o más	0.859	41 %

El desbalance se maneja con el umbral, no rebalanceando

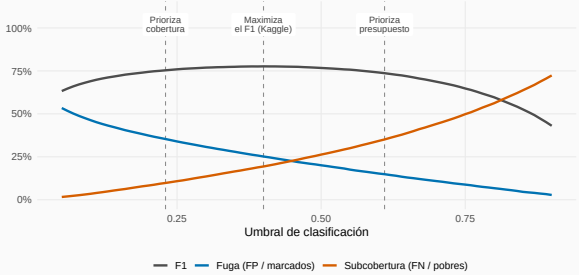


- Con umbral 0.5 el mejor modelo pierde 0.01 de F1; el logit, 0.02.
- **Up-sampling** en el CART: F1 0.702 frente a 0.704 sin rebalanceo. Solo movió el umbral de 0.30 a 0.74.
- Elegir el umbral por F1 ya corrige el desbalance.

El F1 elige un punto entre fuga y subcobertura

Bajar el umbral incluye más pobres, pero también más no pobres

Mejor modelo, predicciones fuera de muestra: tres umbrales para tres objetivos de política



Real	Predicho pobre	Predicho no pobre	Total
Pobre	26,632 (80.6 %)	6,392 (19.4 %)	33,024
No pobre	8,952 (6.8 %)	122,984 (93.2 %)	131,936

Predicciones fuera de muestra de los 164,960 hogares de train, umbral 0.40. % por fila.

Escenario	Umbral	Hogares marcados	Subcobertura	Fuga	F1
Prioriza cobertura	0.23	28 %	10 %	35 %	0.753
Maximiza el F1 (Kaggle)	**0.40**	**22 %**	**19 %**	**25 %**	**0.776**
Prioriza presupuesto	0.61	15 %	35 %	15 %	0.737

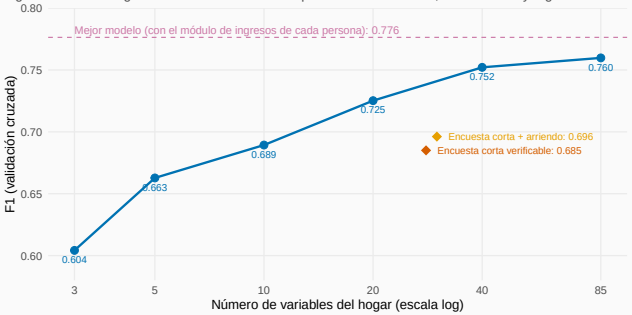
Subcobertura: % de los pobres que el modelo deja por fuera. Fuga: % de los marcados que no son pobres. 20 % de los hogares son pobres.

Con el F1, 1 de cada 5 pobres queda por fuera y 1 de cada 4 beneficiarios no es pobre. Un programa de transferencias suele preferir cobertura: umbral 0.23.

¿Se puede usar con una encuesta corta?

Recortar la encuesta cuesta F1: con 10 variables cae de 0.76 a 0.69

LightGBM a nivel hogar con las k variables más importantes del XGBoost; mismos folds y regla de umbral



Recomendación

1. Recortar cuesta: 10 variables dan 0.69; 40 dan 0.75.
2. Encuesta corta verificable (vivienda, demografía, ocupados, cotizantes en PILA): 0.685.
3. Empleo y formalidad son las preguntas que más rinden por minuto.
4. El módulo de ingresos suma 0.09, pero es caro y manipulable con un subsidio en juego.
5. Fijar el umbral según el costo de cada error.

Conclusiones

1. Información

Entender la regla del DANE y modelar el ingreso de cada persona sube el F1 de 0.760 a 0.776. Es la mayor ganancia después de pasar a boosting.

2. Algoritmo y umbral

Con las mismas variables, el boosting le gana 0.02 al logit y al RF. El umbral (0.40) resuelve el desbalance mejor que rebalancear.

3. Política

El F1 pesa igual fuga y subcobertura: un programa debe elegir su umbral. Una encuesta corta y verificable cuesta unos 0.09 de F1.

0.776	0.77	0.77
F1 validación cruzada	Kaggle público	Kaggle privado