Predecir la pobreza en Colombia

Best Model Deep Dive: un clasificador con un índice de ingreso

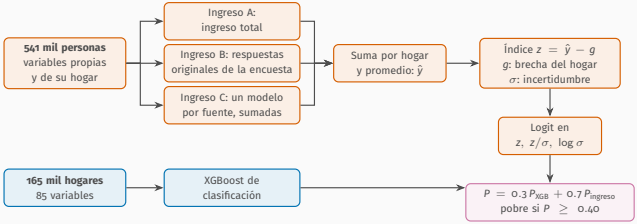
Equipo 1: Aragón, Cadena y Flórez

Problem Set 2 • Octubre de 2026

MECA 4107 Big Data y Machine Learning para Economía Aplicada — Universidad de los Andes

El mejor modelo en una diapositiva

Clasificamos con un índice de ingreso construido desde las personas



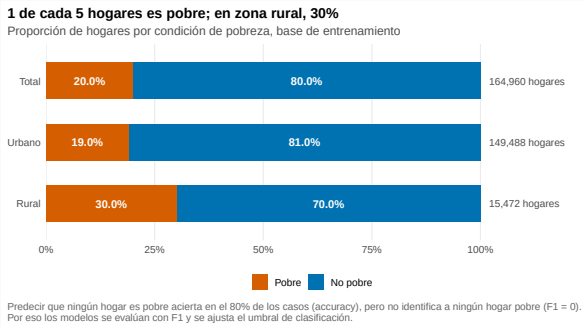
Especificación (boosting): $P = 0.3\,P_{\text{XGBoost}} + 0.7\,P_{\text{ingreso}}$. El XGBoost clasifica con 85 variables del hogar. P_{ingreso}: tres LightGBM predicen el ingreso de cada persona; se suma por hogar, se promedian y se compara con la brecha del hogar; un logit lo convierte en probabilidad según qué tan incierta es la predicción (σ). Pobre si $P \geq 0.40$.

0.77	0.77	0.776
Kaggle público	Kaggle privado	F1 CV

1. Predecir el ingreso de cada persona vale más que cambiar de algoritmo.
2. El desbalance se maneja con el umbral, no rebalanceando.
3. Sin el módulo de ingresos, una encuesta corta cae a F1 0.69.

Cuatro envíos empatan en 0.77 en el público (Kaggle muestra 2 decimales); entre ellos, el CV difiere en menos de 0.001, menos que su error estándar. Presentamos el que el equipo seleccionó.

La pobreza es una regla sobre el ingreso, y 1 de cada 5 hogares es pobre



Predecir que ningún hogar es pobre acierta en el 80% de los casos (accuracy), pero no identifica a ningún hogar pobre (F1 = 0). Por eso los modelos se evalúan con F1 y se ajusta el umbral de clasificación.

Regla oficial del DANE, reescrita por nosotros

$$\text{Pobre} = 1 \iff S < G$$

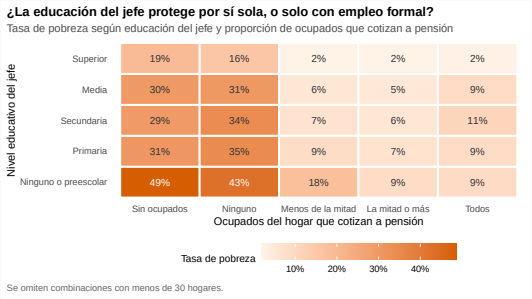
$S = \sum_{j \in UG} \text{Ingtot}_j$: ingreso de las personas
$G = L_p \times N_{ug} - R$: brecha ($R$: arriendo imputado)

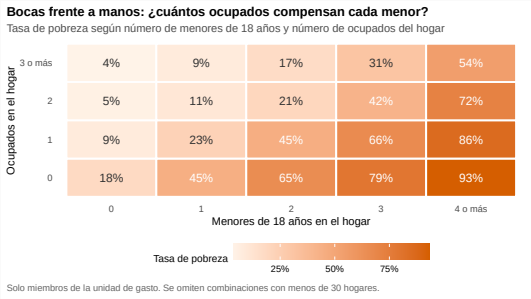
Reconstruida con los datos: reproduce el 99.99 % de la pobreza de train.

- G **se conoce en test** (línea, personas y arriendo): solo hay que predecir S.
- S **vive en las personas**: el ingreso es la suma de lo que gana cada miembro.
- **Desbalance:** 20 % pobres. Con F1, predecir “nadie es pobre” da 0.

Lo que predice la pobreza: trabajo formal, dependencia y vivienda

Con empleo formal la pobreza baja a 2–11 %; con muchos menores y pocos ocupados llega al 93 %





Razonamiento económico: el ingreso del hogar ≈ ocupados × calidad del empleo, repartido entre sus miembros. La vivienda (arriendo por persona) resume el ingreso permanente.

El ingreso tiene cinco fuentes con procesos muy distintos

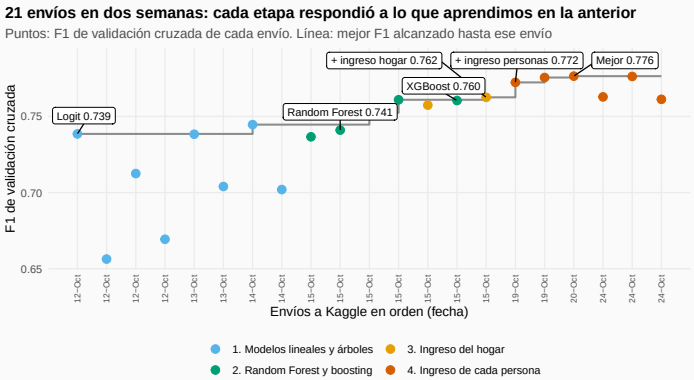
Componente	% del ingreso	% que lo recibe
Trabajo	78	43.7
Pensiones	12	4.8
Ayudas (hogares, instituciones)	5	13.0
Arriendos e intereses	4	3.3
Desocupados	1	1.2

Los componentes suman exactamente `Ingtot` en el 100 % de las personas de train.

Por qué modelar a las personas

- El salario depende de la posición ocupacional, la cotización y el oficio de cada miembro.
- Las pensiones son el 12 % del ingreso pero las recibe el 5 % de las personas: un monto grande y casi fijo.
- Un modelo a nivel hogar solo ve promedios; uno por persona ve quién genera el ingreso.

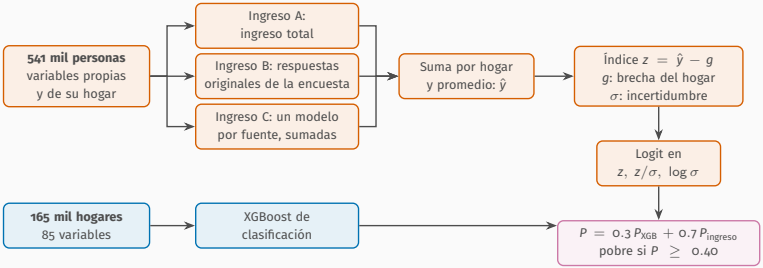
Cómo llegamos aquí: 21 envíos, cuatro etapas



Reglas que mantuvimos en todo el proceso

- Los mismos 5 grupos de validación para todos los modelos.
- Hiperparámetros por búsqueda en grilla con validación cruzada.
- Umbral: el que maximiza el F1 fuera de muestra.
- Decidimos con la validación cruzada, no con el puntaje público.

Arquitectura y entrenamiento: del ingreso de cada persona a una probabilidad



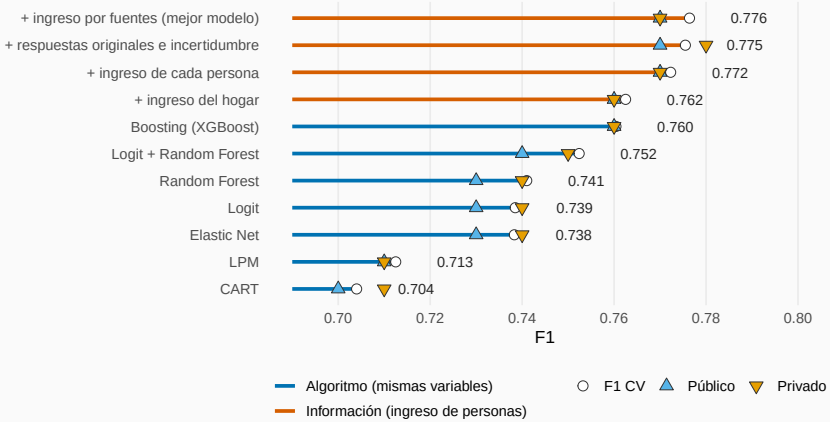
Pieza	Unidad	Algoritmo	Hiperparámetros	F1
Clasificador (peso 0.3)	Hogar	XGBoost	800 árboles de profundidad 6	0.760
Ingreso A: total	Persona	LightGBM Tweedie	2200 árboles de 63 hojas	0.766
Ingreso B: respuestas originales	Persona	LightGBM Tweedie	1000 árboles; más peso cerca de la línea	0.768
Ingreso C: por fuentes	Persona	5 LightGBM Tweedie	5 modelos de 800 árboles	0.767
Índice de ingreso (peso 0.7)	Hogar	Promedio + logit	z, z/σ, $\log\sigma$	0.775
Mejor modelo	**Hogar**	**Ensamble**	**pesos 0.3 / 0.7, umbral 0.40**	**0.776**

F1 de validación cruzada con 5 grupos de hogares (cada persona queda en el grupo de su hogar). Pérdida Tweedie: apta para ingresos con muchos ceros y una cola larga.

Cada pieza suma: el algoritmo llega a 0.76, la información a 0.78

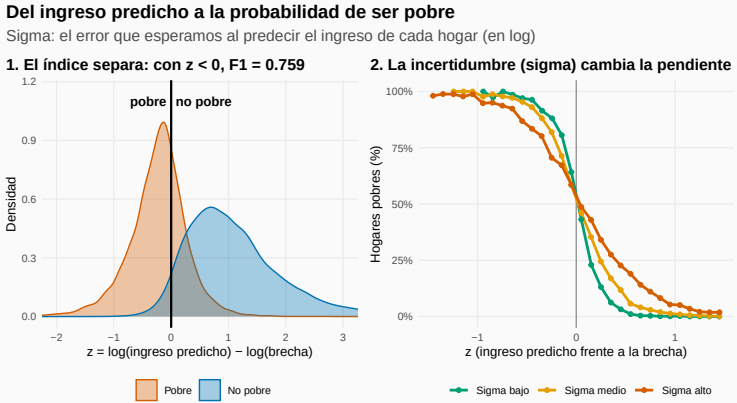
El algoritmo lleva el F1 a 0.76; la información de las personas, a 0.78

F1 de validación cruzada (5 folds) y puntajes de Kaggle (redondeados a 2 decimales)



Público: 20 % de test (unos 13 mil hogares). Privado: 80 % restante.

Del ingreso predicho a la probabilidad de ser pobre



z: distancia entre el ingreso predicho y la brecha. σ: el error que esperamos al predecir el ingreso de ese hogar (bajo para un asalariado, alto para un independiente).

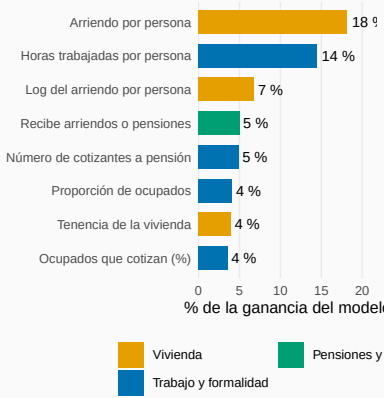
$$\text{logit}\, P(\text{Pobre}) = b_0 + b_1 z + b_2 \frac{z}{\sigma} + b_3 \log \sigma$$

Importancia: vivienda y trabajo formal en el hogar; posición ocupacional en las personas

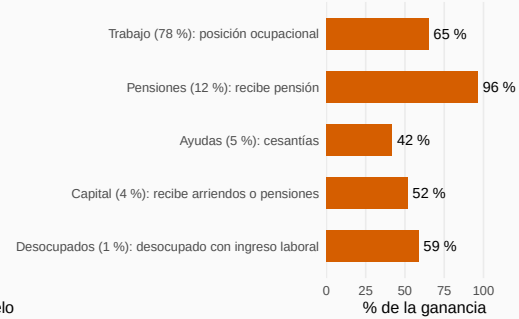
Qué variables usa el mejor modelo

Entre paréntesis, el peso de cada fuente en el ingreso total de las personas

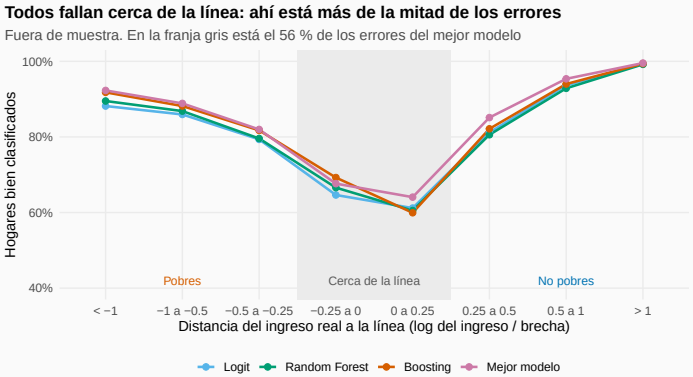
Clasificador del hogar



Ingreso por fuentes: variable principal



Diagnóstico: los errores están cerca de la línea

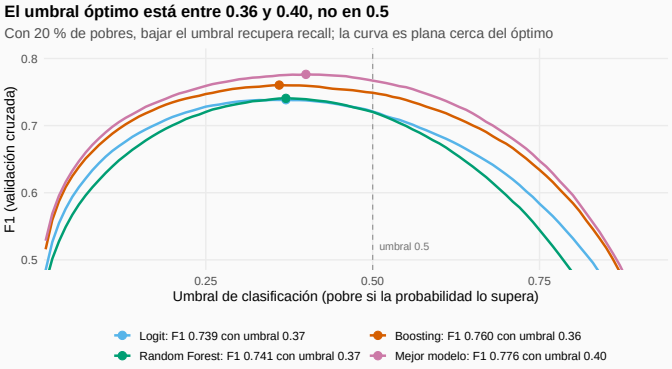


- El 56 % de los errores son hogares a menos de ± 0.25 log de su brecha: ruido casi irreducible.
- Lejos de la línea acierta más del 90 %.

F1 por grupo (mejor modelo)

Grupo	F1	Pobreza
Urbano	0.779	19 %
Rural	0.759	30 %
Hogar de 1 persona	0.654	9 %
Hogar de 6 o más	0.859	41 %

El desbalance se maneja con el umbral, no rebalanceando

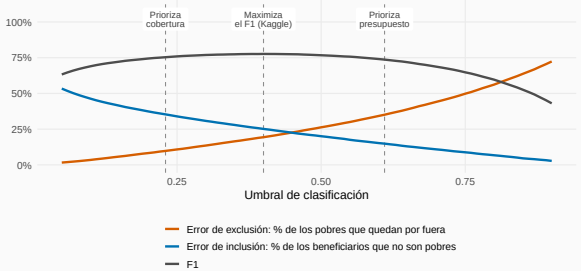


- Con umbral 0.5 el mejor modelo pierde 0.01 de F1; el logit, 0.02.
- **Rebalancear** (duplicar pobres hasta 50/50) en el árbol: F1 0.702 frente a 0.704. Infla todas las probabilidades, pero el orden de los hogares no cambia: el umbral óptimo solo pasó de 0.30 a 0.74.
- Elegir el umbral por F1 ya corrige el desbalance.

El F1 elige un punto entre errores de exclusión e inclusión

Menos exclusión de pobres implica más inclusión de no pobres

Mejor modelo, predicciones fuera de muestra: tres umbrales para tres objetivos de política



Real	Predicho pobre	Predicho no pobre	Total
Pobre	26,632 (80.6 %)	6,392 (19.4 %)	33,024
No pobre	8,952 (6.8 %)	122,984 (93.2 %)	131,936

Predicciones fuera de muestra de los 164,960 hogares de train, umbral 0.40. % por fila.

Escenario	Umbral	Hogares marcados	Error de exclusión	Error de inclusión	F1
Prioriza cobertura	0.23	28 %	10 %	35 %	0.753
Maximiza el F1 (Kaggle)	**0.40**	**22 %**	**19 %**	**25 %**	**0.776**
Prioriza presupuesto	0.61	15 %	35 %	15 %	0.737

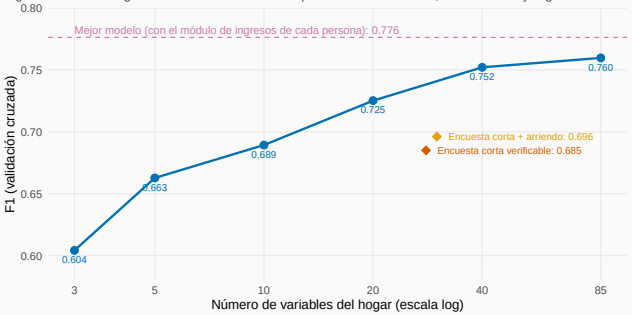
Exclusión: % de los hogares pobres que el modelo deja por fuera. Inclusión: % de los hogares marcados como pobres que no lo son.

Con el F1, 1 de cada 5 pobres queda por fuera (exclusión) y 1 de cada 4 beneficiarios no es pobre (inclusión). Un programa de transferencias suele preferir cobertura: umbral 0.23.

¿Se puede usar con una encuesta corta?

Recortar la encuesta cuesta F1: con 10 variables cae de 0.76 a 0.69

LightGBM a nivel hogar con las k variables más importantes del XGBoost; mismos folds y regla de umbral



Recomendación

1. Recortar cuesta: 10 variables dan 0.69; 40 dan 0.75.
2. Encuesta corta verificable (vivienda, demografía, ocupados, cotizantes en PILA): 0.685.
3. Empleo y formalidad son las preguntas que más rinden por minuto.
4. El módulo de ingresos suma 0.09, pero es caro y manipulable con un subsidio en juego.
5. Fijar el umbral según el costo de cada error.

Conclusiones

1. Información

Entender la regla del DANE y modelar el ingreso de cada persona sube el F1 de 0.760 a 0.776. Es la mayor ganancia después de pasar a boosting.

2. Algoritmo y umbral

Con las mismas variables, el boosting le gana 0.02 al logit y al RF. El umbral (0.40) resuelve el desbalance mejor que rebalancear.

3. Política

El F1 pesa igual los errores de exclusión e inclusión: un programa debe elegir su umbral. Una encuesta corta y verificable cuesta unos 0.09 de F1.

0.776	0.77	0.77
F1 validación cruzada	Kaggle público	Kaggle privado