Predecir la pobreza en Colombia

Algorithm Comparison: el algoritmo importa, la información importa más

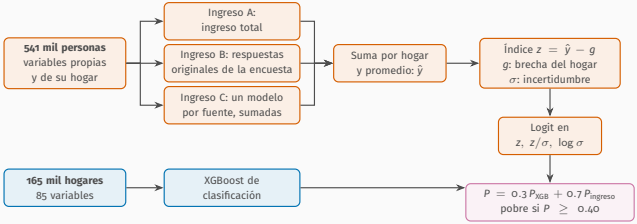
Equipo 1: Aragón, Cadena y Flórez

Problem Set 2 • Octubre de 2026

MECA 4107 Big Data y Machine Learning para Economía Aplicada — Universidad de los Andes

El mejor modelo en una diapositiva

Clasificamos con un índice de ingreso construido desde las personas



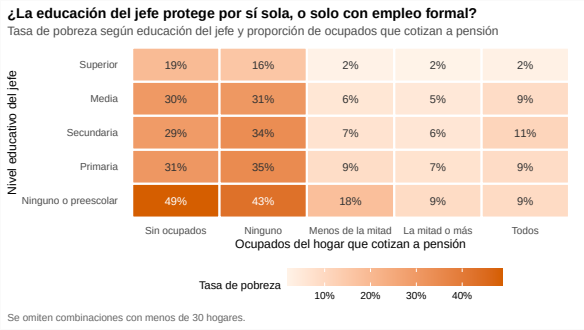
Especificación (boosting): $P = 0.3\,P_{\text{XGBoost}} + 0.7\,P_{\text{ingreso}}$. El XGBoost clasifica con 85 variables del hogar. P_{ingreso}: tres LightGBM predicen el ingreso de cada persona; se suma por hogar, se promedian y se compara con la brecha del hogar; un logit lo convierte en probabilidad según qué tan incierta es la predicción (σ). Pobre si $P \geq 0.40$.

0.77	0.77	0.776
Kaggle público	Kaggle privado	F1 CV

1. Predecir el ingreso de cada persona vale más que cambiar de algoritmo.
2. El desbalance se maneja con el umbral, no rebalanceando.
3. Sin el módulo de ingresos, una encuesta corta cae a F1 0.69.

Cuatro envíos empatan en 0.77 en el público (Kaggle muestra 2 decimales); entre ellos, el CV difiere en menos de 0.001, menos que su error estándar. Presentamos el que el equipo seleccionó.

Por qué este problema premia la flexibilidad y la información



- **Interacciones:** la educación protege sobre todo cuando el trabajo es informal. Un logit las necesita a mano; los árboles las encuentran solos.
- **Umbrales:** la pobreza es $\mathbb{1}(S < G)$, un corte sobre el ingreso. Los árboles cortan.
- **Desbalance:** 20 % pobres. Todos los modelos eligen su umbral con la misma regla.
- **Información:** el ingreso está en las personas; un modelo a nivel hogar solo ve agregados.

Un campo nivelado: la diferencia es del algoritmo

Lo mismo para todos los modelos

- **Base:** 164,960 hogares, 85 predictores (hogar + personas agregadas), sin variables de ingreso.
- **Validación:** los mismos 5 folds estratificados (semilla 2026).
- **Métrica:** F1 fuera de muestra.
- **Umbral:** el que maximiza el F1 sobre las predicciones fuera de muestra (grilla 0.01–0.99).
- **Hiperparámetros:** búsqueda en grilla con validación cruzada.

Lo que cambia

- **LPM y Logit:** efectos aditivos (MCO y máxima verosimilitud).
- **Elastic Net:** logit con penalización $L_1 + L_2$.
- **CART:** un árbol podado por *cp*.
- **Random Forest:** promedio de 300 árboles profundos, cada uno con una muestra distinta de hogares y de variables.
- **Boosting:** árboles poco profundos en secuencia, cada uno corrige al anterior.

El mejor modelo rompe el campo nivelado a propósito: agrega información (el ingreso de cada persona). Se compara aparte.

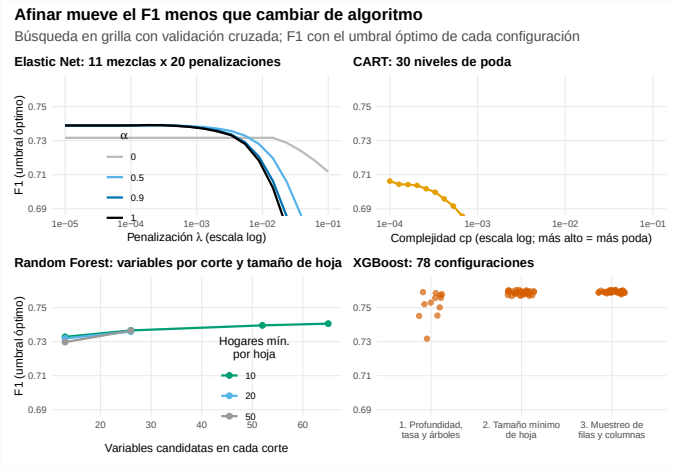
Los seis algoritmos: boosting gana con las mismas variables

		Validación cruzada (5 folds)				Kaggle	
Algoritmo	Especificación	F1 CV	Precisión	Recall	Umbral	Público	Privado
LPM	MCO con todas las variables	0.713	0.660	0.775	0.37	0.71	0.71
Logit	85 variables menos 8 redundantes	0.739	0.706	0.775	0.37	0.73	0.74
Elastic Net	Mezcla L1/L2 $\alpha = 0.9$, penalización $\lambda = 0.0003$	0.738	0.700	0.782	0.36	0.73	0.74
CART	Un árbol podado a 420 hojas	0.704	0.703	0.705	0.30	0.70	0.71
Random Forest	300 árboles, 65 variables candidatas por corte	0.741	0.700	0.787	0.37	0.73	0.74
Boosting	XGBoost: 800 árboles de profundidad 6	0.760	0.718	0.809	0.36	0.76	0.76
Mejor modelo	**0.3 XGBoost + 0.7 índice de ingreso de las personas**	**0.776**	**0.748**	**0.806**	**0.40**	**0.77**	**0.77**

Los dos más cercanos al boosting en Kaggle son Random Forest y Logit (0.73 público; 0.741 y 0.739 en CV).

Naive Bayes no se usó: supone independencia entre variables muy correlacionadas.

Búsqueda de hiperparámetros: afinar mueve poco el F1



- **Elastic Net:** el óptimo es casi sin penalización ($\lambda \approx 0.0003$): regularizar no ayuda con 165 mil hogares.
- **RF:** lo que importa es cuántas variables candidatas ve cada corte (13 a 65); árboles profundos.
- **XGBoost:** 78 configuraciones entre 0.757 y 0.760: una meseta.

Boosting frente a Random Forest y Logit, en igualdad de condiciones

Modelo	F1 (media de 5 folds)	Precisión	Recall	Umbral	Diferencia vs. Boosting
Logit	0.739 (0.006)	0.706	0.775	0.37	-0.022 (0.002)
Random Forest	0.741 (0.003)	0.700	0.787	0.37	-0.020 (0.001)
Boosting	0.760 (0.004)	0.718	0.809	0.36	—
Mejor modelo	0.776 (0.004)	0.748	0.806	0.40	+0.016 (0.001)

Entre paréntesis: desviación estándar entre folds (F1) y error estándar de la diferencia pareada por fold.

Logit (0.739)

Efectos aditivos. Las interacciones económicas hechas a mano sumaron solo 0.001.

Random Forest (0.741)

Capta interacciones, pero promediar árboles profundos reduce varianza, no sesgo. Lo que más pesa es cuántas variables ve cada corte.

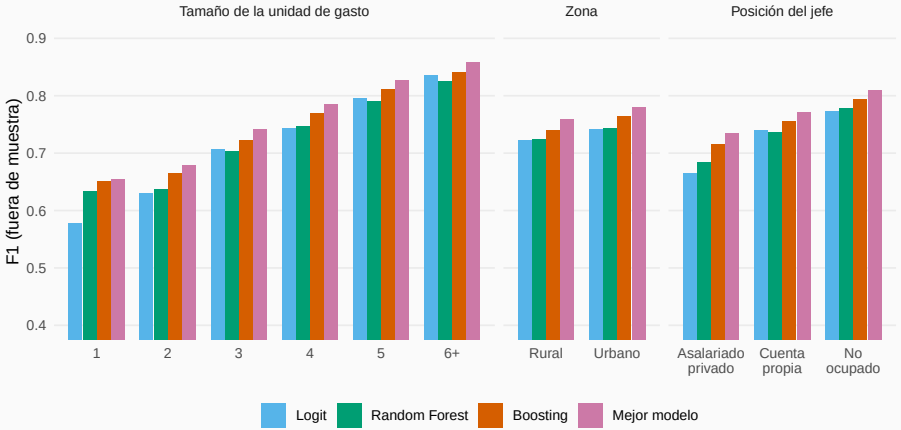
Boosting (0.760)

Cada árbol corrige el error del anterior: reduce sesgo. Ventaja de +0.02, entre 10 y 15 veces su error estándar.

Dónde gana el boosting: en todos los grupos, sobre todo en hogares pequeños

La ventaja del Boosting se mantiene en todos los grupos

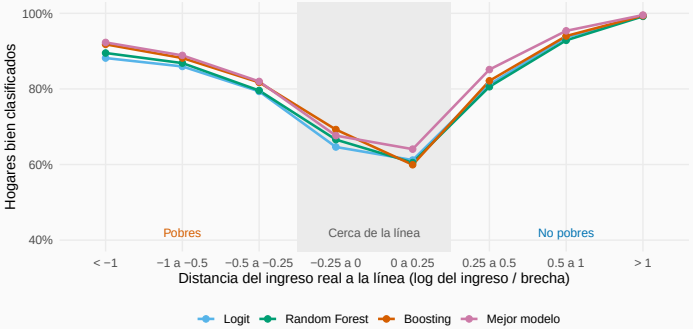
F1 fuera de muestra por grupo; los hogares de 1 y 2 personas tienen poca pobreza y su F1 es bajo para todos



Dónde fallan todos: cerca de la línea de pobreza

Todos fallan cerca de la línea: ahí está más de la mitad de los errores

Fuera de muestra. En la franja gris está el 56 % de los errores del mejor modelo

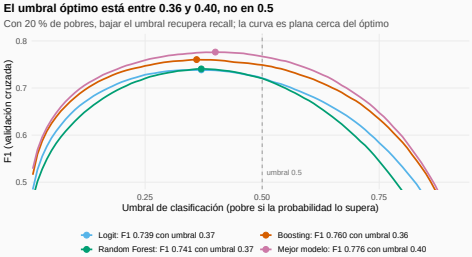


- Lejos de la línea, todos aciertan más del 90 %.
- Cerca de la línea (± 0.25 log) aciertan 60–70 %: ahí está más de la mitad de los errores.
- Ningún algoritmo arregla eso; solo más información sobre el ingreso.

El desbalance: tres estrategias, el umbral gana

Algoritmo	Sin corrección (umbral 0.5)	Umbral óptimo	Ganancia	Up-sampling
Logit	0.721	0.739 (0.37)	+0.018	—
Elastic Net	0.719	0.738 (0.36)	+0.019	—
CART	0.695	0.704 (0.30)	+0.008	0.702 (0.74)
Random Forest	0.720	0.741 (0.37)	+0.020	—
Boosting (XGBoost)	0.749	0.760 (0.36)	+0.011	—
Mejor modelo	0.767	0.776 (0.40)	+0.009	—

F1 fuera de muestra (validación cruzada). Entre paréntesis, el umbral. Up-sampling: hogares pobres duplicados hasta 50/50 en el entrenamiento.

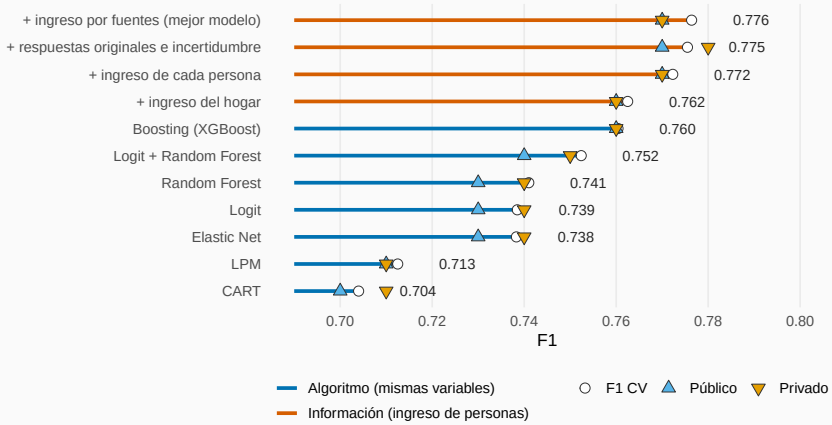


- Bajar el umbral de 0.5 al óptimo sube el F1 entre 0.01 y 0.02 en todos los algoritmos.
- Duplicar pobres (up-sampling) no agregó nada: solo cambió la escala de la probabilidad.

Del mejor algoritmo al mejor modelo: la información

El algoritmo lleva el F1 a 0.76; la información de las personas, a 0.78

F1 de validación cruzada (5 folds) y puntajes de Kaggle (redondeados a 2 decimales)



Público: 20 % de test (unos 13 mil hogares). Privado: 80 % restante.

Los modelos más cercanos: los que llegan a 0.77 usan el ingreso de cada persona

Modelo	Ingreso que usa	Envió	F1 CV	Público	Privado
Mejor modelo: clasificador + ingreso A, B y C con sigma	**Personas**	**Cadena**	**0.7764**	**0.77**	**0.77**
LightGBM con restricciones de signo + índice de ingreso	Personas	Flórez	0.7762	0.77	0.77
Clasificador + ingreso A y B con sigma	Personas	Cadena	0.7755	0.77	0.78
Clasificador + ingreso A	Personas	Cadena	0.7723	0.77	0.77
LightGBM con restricciones de signo + XGBoost con brecha	Ninguno	Flórez	0.7628	0.76	0.76
Clasificador + XGBoost del ingreso del hogar	Hogar	Cadena	0.7625	0.76	0.76
XGBoost + LightGBM del ingreso del hogar	Hogar	Aragón	0.7612	0.76	0.76
Logit + Random Forest + XGBoost	Ninguno	Cadena	0.7609	0.76	0.76
XGBoost de clasificación	Ninguno	Cadena	0.7604	0.76	0.76

Todos son modelos de boosting (XGBoost o LightGBM). Kaggle muestra dos decimales: los cuatro primeros empatan en el público.

Todos son de boosting. Lo que separa 0.77 de 0.76 no es el algoritmo sino la información: sin el ingreso de cada persona, ningún modelo pasa de 0.76.

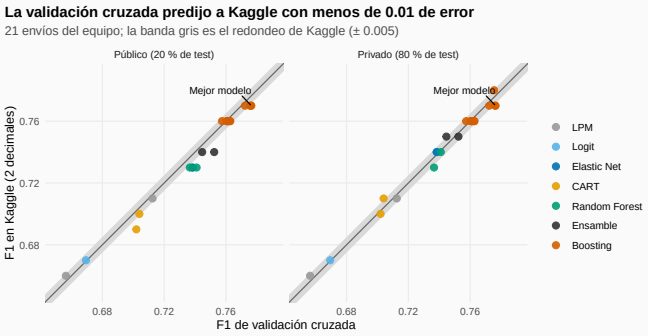
Comparación detallada: el mejor frente a los dos que le siguen

Modelo	Qué cambia	F1 CV	Precisión	Recall	Dif. (EE)	Corr.	Cambian	Público	Privado
Mejor modelo	**Clasificador + ingreso A, B y C**	**0.7764**	**0.748**	**0.806**	**—**	**1.000**	**—**	**0.77**	**0.77**
Ingreso A + B con sigma	Sin el ingreso por fuentes (C)	0.7755	0.747	0.807	-0.0009 (0.0006)	0.999	0.7 %	0.77	0.78
LightGBM monótono + índice	LightGBM monótono (0.2) + índice (0.8)	0.7762	0.754	0.800	-0.0001 (0.0007)	0.999	0.8 %	0.77	0.77

Mismos 5 grupos de validación. Dif. (EE): diferencia de F1 con el mejor, pareada por grupo, y su error estándar. Corr.: correlación de probabilidades con el mejor. Cambian: % de hogares clasificados distinto que con el mejor.

- Las diferencias de F1 (0.0009 y 0.0001) son menores que su error estándar: los tres están empatados.
- Clasifican distinto a menos del 1 % de los hogares; sus probabilidades tienen correlación de 0.999.
- El de Flórez cambia el balance: más precisión (0.754) y menos recall (0.800), con el mismo F1.
- El 0.78 del privado de la versión A + B es ruido del mismo tamaño: elegimos por validación cruzada.

La validación cruzada predijo a Kaggle



- Correlación CV–privado: 0.99 en 21 envíos.
- Decidimos con el CV, no con el público (ruido de ± 0.006 con 13 mil hogares).
- El ensamble con dos modelos de ingreso sacó 0.78 en el privado y el elegido (tres) 0.77, con CV de 0.7755 frente a 0.7764: es ruido.

¿Qué modelo le recomendaríamos a una entidad del gobierno?

Modelo	F1 CV	Privado	Interpretabilidad	Información	Entrenamiento
Logit	0.739	0.74	Alta: coeficientes	Hogar (85 variables)	Minutos
Random Forest	0.741	0.74	Media: importancia	Hogar (85 variables)	25 min por bosque
Boosting (XGBoost)	0.760	0.76	Media: importancia	Hogar (85 variables)	1 min por ajuste
LightGBM con 10 variables	0.689	—	Media: 10 variables	Hogar (10 variables)	1 min
Mejor modelo	**0.776**	**0.77**	**Baja: 9 modelos de árboles y un logit**	**Hogar + ingresos de cada persona**	**2 horas**

Complejidad frente a desempeño. De logit a boosting: +0.02 sin perder variables. Del boosting al mejor modelo: +0.016, pero con nueve modelos de árboles y el módulo de ingresos.

Recomendación. Para focalizar: boosting a nivel hogar con preguntas verificables y un umbral elegido por el costo de los errores. El mejor de Kaggle no es necesariamente el mejor instrumento.