Predecir la pobreza en Colombia

Algorithm Comparison: el algoritmo importa, la información importa más

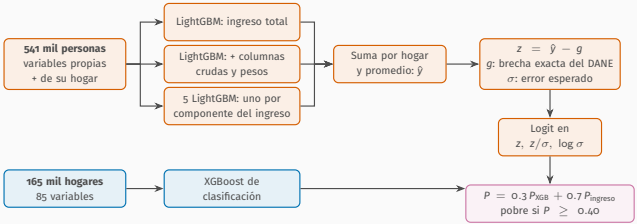
Equipo 1: Aragón, Cadena y Flórez

Problem Set 2 • Octubre de 2026

MECA 4107 Big Data y Machine Learning para Economía Aplicada — Universidad de los Andes

El mejor modelo en una diapositiva

Clasificamos con un índice de ingreso construido desde las personas



Especificación (boosting): $P = 0.3\,P_{\text{XGBoost}} + 0.7\,P_{\text{ingreso}}$. P_{ingreso}: promedio de tres LightGBM Tweedie del ingreso de cada persona, sumado por hogar, comparado con la brecha exacta del DANE y calibrado con la incertidumbre σ del hogar. Umbral 0.40, elegido por F1 fuera de muestra.

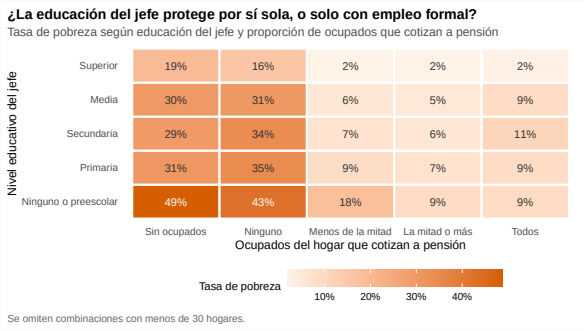
0.77 Kaggle público

0.77 Kaggle privado

0.776 F1 CV

1. Predecir el ingreso de cada persona vale más que cambiar de algoritmo.
2. El desbalance se maneja con el umbral, no rebalanceando.
3. Sin el módulo de ingresos, una encuesta corta cae a F1 0.69.

Por qué este problema premia la flexibilidad y la información



- **Interacciones:** la educación protege sobre todo cuando el trabajo es informal. Un logit las necesita a mano; los árboles las encuentran solos.
- **Umbrales:** la pobreza es $\mathbb{1}(S < G)$, un corte sobre el ingreso. Los árboles cortan.
- **Desbalance:** 20 % pobres. Todos los modelos eligen su umbral con la misma regla.
- **Información:** el ingreso está en las personas; un modelo a nivel hogar solo ve agregados.

Un campo nivelado: la diferencia es del algoritmo

Lo mismo para todos los modelos

- **Base:** 164,960 hogares, 85 predictores (hogar + personas agregadas), sin variables de ingreso.
- **Validación:** los mismos 5 folds estratificados (semilla 2026).
- **Métrica:** F1 fuera de muestra.
- **Umbral:** el que maximiza el F1 sobre las predicciones fuera de muestra (grilla 0.01–0.99).
- **Hiperparámetros:** búsqueda en grilla con validación cruzada.

Lo que cambia

- **LPM y Logit:** efectos aditivos (MCO y máxima verosimilitud).
- **Elastic Net:** logit con penalización $L_1 + L_2$.
- **CART:** un árbol podado por *cp*.
- **Random Forest:** promedio de 300 árboles profundos (bagging + mtry).
- **Boosting:** árboles poco profundos en secuencia, cada uno corrige al anterior.

El mejor modelo rompe el campo nivelado a propósito: agrega información (el ingreso de cada persona). Se compara aparte.

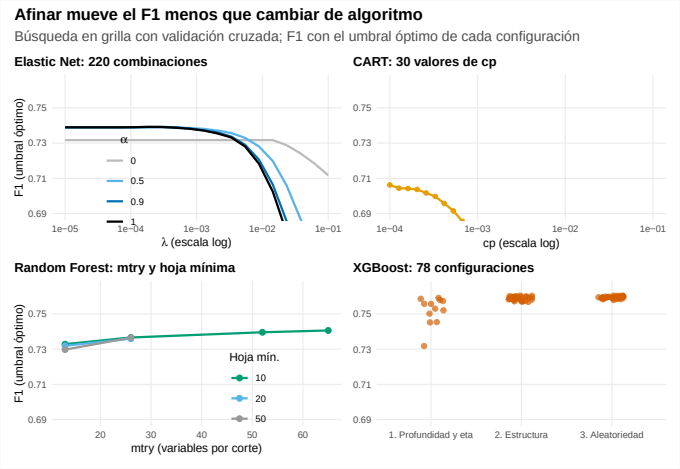
Los seis algoritmos: boosting gana con las mismas variables

		Validación cruzada (5 folds)				Kaggle	
Algoritmo	Especificación	F1 CV	Precisión	Recall	Umbral	Público	Privado
LPM	MCO con todas las variables	0.713	0.660	0.775	0.37	0.71	0.71
Logit	Todas las variables menos 8 redundantes	0.739	0.706	0.775	0.37	0.73	0.74
Elastic Net	$\alpha = 0.9$, $\lambda = 0.0003$	0.738	0.700	0.782	0.36	0.73	0.74
CART	$cp = 0.00013$ (420 hojas)	0.704	0.703	0.705	0.30	0.70	0.71
Random Forest	mtry = 65, hoja mín. 10, 300 árboles	0.741	0.700	0.787	0.37	0.73	0.74
Boosting	XGBoost: prof. 6, $\eta = 0.05$, 800 árboles	0.760	0.718	0.809	0.36	0.76	0.76
Mejor modelo	**0.3 XGBoost + 0.7 ingreso de personas (LightGBM) con σ**	**0.776**	**0.748**	**0.806**	**0.40**	**0.77**	**0.77**

Los dos más cercanos al boosting en Kaggle son Random Forest y Logit (0.73 público; 0.741 y 0.739 en CV).

Naive Bayes no se usó: supone independencia entre variables muy correlacionadas.

Búsqueda de hiperparámetros: afinar mueve poco el F1



- **Elastic Net:** el óptimo es casi sin penalización ($\lambda \approx 0.0003$): regularizar no ayuda con 165 mil hogares.
- **RF:** lo que importa es mtry; árboles profundos (hoja 10).
- **XGBoost:** 78 configuraciones entre 0.757 y 0.760: una meseta.

Boosting frente a Random Forest y Logit, en igualdad de condiciones

Modelo	F1 (media de 5 folds)	Precisión	Recall	Umbral	Diferencia vs. Boosting
Logit	0.739 (0.006)	0.706	0.775	0.37	-0.022 (0.002)
Random Forest	0.741 (0.003)	0.700	0.787	0.37	-0.020 (0.001)
Boosting	0.760 (0.004)	0.718	0.809	0.36	—
Mejor modelo	0.776 (0.004)	0.748	0.806	0.40	+0.016 (0.001)

Entre paréntesis: desviación estándar entre folds (F1) y error estándar de la diferencia pareada por fold.

Logit (0.739)

Efectos aditivos. Las interacciones económicas hechas a mano sumaron solo 0.001.

Random Forest (0.741)

Capta interacciones, pero promediar árboles profundos reduce varianza, no sesgo. Lo que más pesa es mtry.

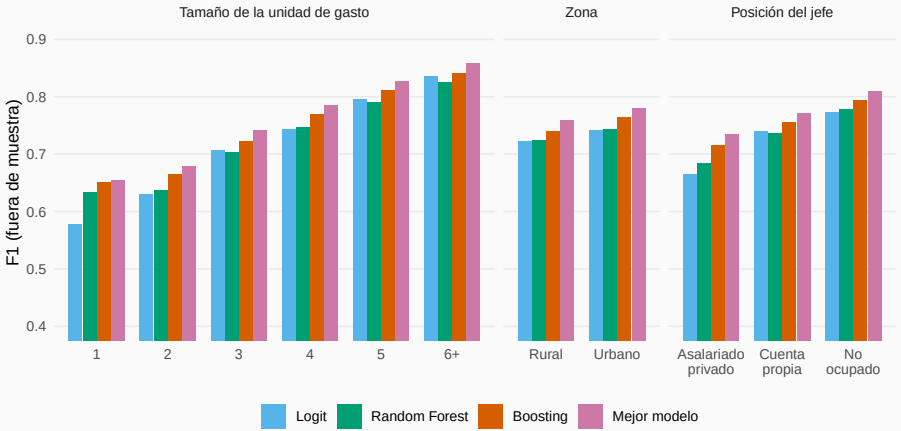
Boosting (0.760)

Cada árbol corrige el error del anterior: reduce sesgo. Ventaja de +0.02, entre 10 y 15 veces su error estándar.

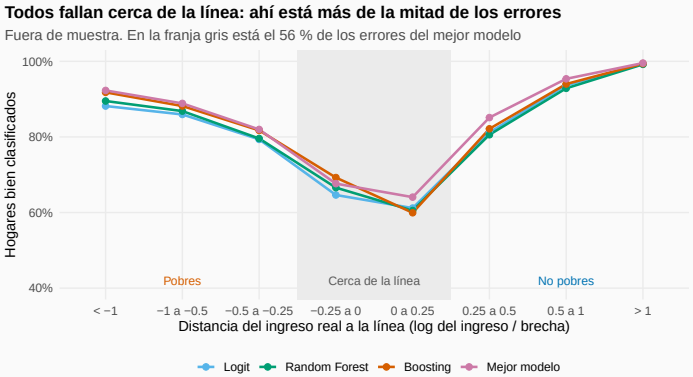
Dónde gana el boosting: en todos los grupos, sobre todo en hogares pequeños

La ventaja del Boosting se mantiene en todos los grupos

F1 fuera de muestra por grupo; los hogares de 1 y 2 personas tienen poca pobreza y su F1 es bajo para todos



Dónde fallan todos: cerca de la línea de pobreza

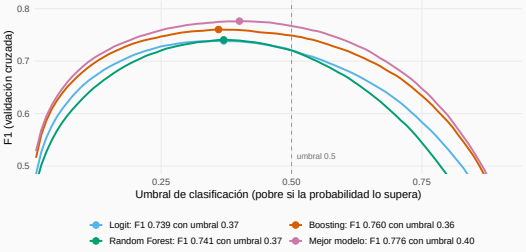


- Lejos de la línea, todos aciertan más del 90 %.
- Cerca de la línea (± 0.25 log) aciertan 60–70 %: ahí está más de la mitad de los errores.
- Ningún algoritmo arregla eso; solo más información sobre el ingreso.

El desbalance se maneja igual para todos: con el umbral

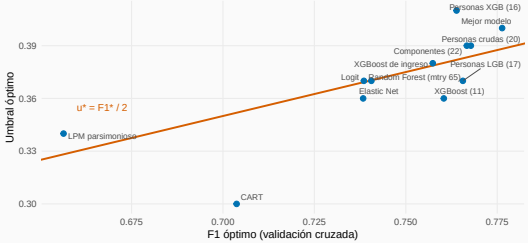
El umbral óptimo está entre 0.36 y 0.40, no en 0.5

Con 20 % de pobres, bajar el umbral recupera recall; la curva es plana cerca del óptimo



Mejor modelo, umbral más alto: el umbral óptimo es la mitad del F1

Cada punto es un modelo; la recta es la predicción teórica para probabilidades calibradas



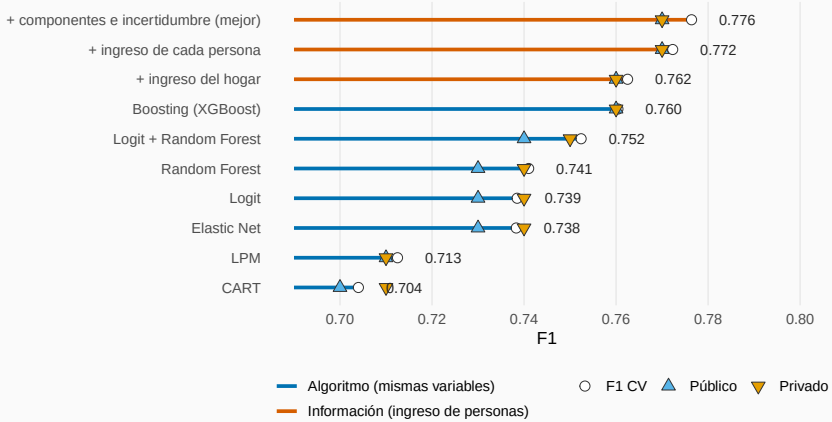
Fuente de la regla: Lipton, Elkan y Naryanaswamy (2014), Optimal Thresholding of Classifiers to Maximize F1.

Con umbral 0.5 el logit pierde 0.02 y el boosting 0.01. El up-sampling en CART no cambió el F1 (0.702 frente a 0.704). Con probabilidades calibradas, el umbral óptimo es $F1^*/2$: el mejor modelo sube su umbral a 0.40.

Del mejor algoritmo al mejor modelo: la información

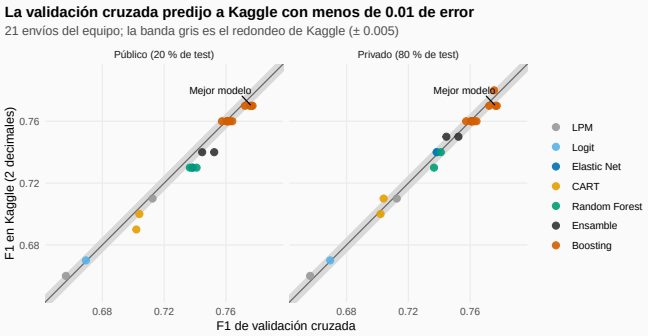
El algoritmo lleva el F1 a 0.76; la información de las personas, a 0.78

F1 de validación cruzada (5 folds) y puntajes de Kaggle (redondeados a 2 decimales)



Público: 20 % de test (unos 13 mil hogares). Privado: 80 % restante.

La validación cruzada predijo a Kaggle



- Correlación CV–privado: 0.99 en 21 envíos.
- Decidimos con el CV, no con el público (ruido de ± 0.006 con 13 mil hogares).
- El ensamble 17 + 20 con σ sacó 0.78 en el privado y el elegido 0.77, con CV 0.7755 frente a 0.7764: es ruido, no una razón para elegir por el público.

¿Qué modelo le recomendaríamos a una entidad del gobierno?

Modelo	F1 CV	Privado	Interpretabilidad	Información	Entrenamiento
Logit	0.739	0.74	Alta: coeficientes	Hogar (85 variables)	Minutos
Random Forest	0.741	0.74	Media: importancia	Hogar (85 variables)	25 min por bosque
Boosting (XGBoost)	0.760	0.76	Media: importancia	Hogar (85 variables)	1 min por ajuste
LightGBM con 10 variables	0.689	—	Media: 10 variables	Hogar (10 variables)	1 min
Mejor modelo	**0.776**	**0.77**	**Baja: 7 modelos encadenados**	**Hogar + ingresos de cada persona**	**2 horas**

Complejidad frente a desempeño. De logit a boosting: +0.02 sin perder variables. Del boosting al mejor modelo: +0.016, pero con siete modelos y el módulo de ingresos.

Recomendación. Para focalizar: boosting a nivel hogar con preguntas verificables y un umbral elegido por el costo de los errores. El mejor de Kaggle no es necesariamente el mejor instrumento.